

1. Familiarizarnos con el Dataset

Generar propts para desarrollar este proceso con un agente de Inteligencia Artificial

Actúa como un Agente Autónomo de Ingeniería de Datos. Tu tarea es procesar directamente los dos archivos CSV cargados en tu entorno (`FUENTE\_DATOS\_1.csv` y `FUENTE\_DATOS\_2.csv`), replicar el flujo ETL de Kettle/Spoon mediante Python en tu entorno de ejecución (Code Interpreter) y entregarme el archivo final procesado listo para descargar.

ARCHIVOS DE ENTRADA

1. ****Dataset 1 (Rama Superior - Personas/Hogares):**** `FUENTE\_DATOS\_1.csv`
2. ****Dataset 2 (Rama Inferior - Tabla Principal/Derecha):**** `FUENTE\_DATOS\_2.csv`

SECUENCIA DE EJECUCIÓN (ETL COMPLETO)

Paso 1: Carga y Tratamiento Estricto de Claves

- Carga `FUENTE\_DATOS\_1.csv` y `FUENTE\_DATOS\_2.csv` asegurando que las columnas clave `I01`, `I02`, `I10`, `INH` se lean estrictamente como CADENAS DE TEXTO (`str`).
- Limpia espacios en blanco e impón relleno de ceros a la izquierda (`zfill`) si se detecta pérdida de ceros iniciales en los códigos.

Paso 2: Transformación de Dataset 1 (`FUENTE\_DATOS\_1.csv`)

1. ****Eliminar columnas iniciales:****

Descarta únicamente: `['P1004', 'P1005', 'P1001I', 'GEDAD']`.

2. ****Renombrar columnas:****

- `I01` -> `provincia`
- `I02` -> `canton`
- `I10` -> `num\_vivienda`
- `INH` -> `num\_hogar`
- `P00` -> `num\_persona`
- `P01` -> `rol\_hogar`
- `P02` -> `sexo\_nacim`
- `P03` -> `anios`
- `P11` -> `cultura`
- `P16` -> `tip\_colegio`
- `P17` -> `nivel\_academic`
- `P29` -> `ocupacion`
- `P31` -> `estado\_conyugal`
- `P3303` -> `hijos`
- `AUR` -> `area`
- `TDFUNC` -> `discapacidad`
- `P10R` -> `idiomas`

3. ****Limpieza y Estandarización de Variables:****

Aplica conversión a minúsculas y eliminación de espacios no visibles en: `tip\_colegio`, `ocupacion`, `estado\_conyugal`, `hijos`, `idiomas`.

Paso 3: Transformación de Dataset 2 (`FUENTE\_DATOS\_2.csv`)

1. ****Renombrar columnas:****

- `I01` -> `provincia`
- `I02` -> `canton`
- `I10` -> `num\_vivienda`
- `INH` -> `num\_hogar`
- `H09` -> `tipo\_vivienda`

Paso 4: Cruce (Right Outer Join)

- Realiza un ****Right Join**** usando como tabla preserve/derecha a `FUENTE\_DATOS\_2.csv`.
- Claves compuestas de unión: `['provincia', 'canton', 'num\_vivienda', 'num\_hogar']`.
- La tabla resultante debe preservar el 100% de los registros de `FUENTE\_DATOS\_2.csv`.

Paso 5: Post-Procesamiento y Salida

- Elimina las columnas duplicadas o sufijadas generadas por la unión: `['provincia\_1', 'canton\_1', 'num\_vivienda\_1', 'num\_hogar\_1']`.
- Exporta el resultado final en `/mnt/data/resultado\_censal\_unificado.csv` con codificación UTF-8 sin índice.

ENTREGABLES REQUERIDOS

1. ****Enlace de Descarga:**** Genera y guarda el archivo resultante en el directorio de trabajo y proporcióname el enlace directo de descarga.
2. ****Informe de Auditoría en Texto:****
 - Cantidad final de registros exportados.
 - Conteo de coincidencias exitosas (filas de `FUENTE\_DATOS\_2.csv` con datos de `FUENTE\_DATOS\_1.csv` asignados vs. filas sin match).
 - Verificación de que las claves compuestas mantuvieron su formato de cadena de texto sin pérdida de ceros.

SEGUNDA ETAPA:

Actúa como un Analista de Datos Senior. Tu tarea es realizar un Análisis Exploratorio de Datos (EDA) completo y automatizado sobre el conjunto de datos cargado ('resultado_censal_unificado.csv'), replicando el flujo analítico de Orange Data Mining mediante ejecución de código en Python.

1. SELECCIÓN Y FILTRADO DE VARIABLES (Equivalente a 'Select Columns')

- IGNORAR/EXCLUIR del análisis estadístico y de gráficos las columnas clave e identificadores: `['provincia', 'canton', 'num\_vivienda', 'num\_hogar', 'num\_persona']`
- CONCENTRAR EL ANÁLISIS exclusivamente en las 13 variables de interés (Features): `['rol\_hogar', 'sexo\_nacim', 'anios', 'cultura', 'tip\_colegio', 'nivel\_academic', 'ocupacion', 'estado\_conyugal', 'hijos', 'area', 'discapacidad', 'idiomas', 'tipo\_vivienda']`

2. ESTADÍSTICA DESCRIPTIVA (Equivalente a 'Feature Statistics')

Genera un informe con las métricas descriptivas principales para las 13 variables seleccionadas:

- Para variables numéricas (ej. 'anios', 'hijos'): media, mediana, desviación estándar, mínimo, máximo y porcentaje de datos faltantes.

- Para variables categóricas (ej. 'nivel_academic', 'ocupacion', 'tipo_vivienda'): recuento total, categorías únicas, moda (categoría dominante) y su porcentaje sobre el total.
- Incluye una síntesis interpretativa en lenguaje sencillo sobre la calidad general de los datos y los patrones evidentes.

3. FRENTE DE VISUALIZACIÓN

A. Gráficos de Barras (Equivalente a 'Bar Plot')

- Crea gráficos de barras ordenados de mayor a menor frecuencia para las variables categóricas principales: 'nivel_academic', 'ocupacion', 'estado_conyugal' y 'tipo_vivienda'.
- Muestra etiquetas de porcentaje sobre cada barra.

B. Análisis de Distribución (Equivalente a 'Distributions')

- Genera histogramas con curvas de densidad de kernel (KDE) para las variables numéricas ('anios', 'hijos').
- Segmenta las distribuciones utilizando 'sexo_nacim' o 'area' como variable de agrupación para comparar comportamientos demográficos.

C. Análisis de Densidad y Dispersión (Equivalente a 'Violin Plot')

- Construye Diagramas de Violín (Violin Plots) relacionando la variable 'anios' (edad) frente a categorías como 'nivel_academic' y 'estado_conyugal'.
- Incluye la mediana y los cuartiles dentro de cada estructura de violín para observar la variación de edad según cada condición.

4. ENTREGABLES ESPERADOS

1. Gráficos de alta resolución con títulos descriptivos en español, etiquetas claras en los ejes y una paleta de colores profesional.
2. Resumen ejecutivo con 3 hallazgos demográficos y socioeconómicos clave derivados del análisis, explicados de forma clara para tomadores de decisiones no técnicos.

ANALÍTICA

Actúa como un Analista de Datos Senior. Tu objetivo es responder a la siguiente pregunta demográfica usando únicamente las variables numéricas del archivo 'resultado_censal_unificado.csv':

¿Cómo se relaciona la edad de las personas ('anios') con el número de hijos nacidos vivos ('hijos') y cuál es la evolución del promedio de hijos según la cohorte de edad?

PASOS A EJECUTAR:

1. FILTRADO Y LIMPIEZA NUMÉRICA:

- Reemplaza el valor centinela 99 en la variable 'hijos' por NaN.
- Filtra a la población femenina de 12 años o más (universo válido de fecundidad).
- Elimina valores nulos en 'anios' e 'hijos'.

2. ANÁLISIS ESTADÍSTICO NUMÉRICO:

- Calcula la media, mediana, desviación estándar y máximo de 'hijos' agrupados por rangos de edad (12-19, 20-29, 30-39, 40-49, 50-59, 60+).
- Calcula la correlación de Spearman entre 'años' e 'hijos'.

3. VISUALIZACIÓN DE DISPERSIÓN Y DENSIDAD:

- Genera un Boxplot o Diagrama de Violín de 'años' agrupado por el número de 'hijos' (0 a 10+).
- Genera un gráfico de líneas que muestre el promedio de hijos en el eje Y frente a la edad exacta (eje X).

4. ENTREGABLE EJECUTIVO (PARA DIRECTIVOS):

- Redacta 3 hallazgos clave explicando la brecha generacional (ej. "Las mujeres de 60 años o más tienen en promedio X hijos más que las mujeres de 30 años a su misma edad").
- Cero jerga compleja: explica la correlación en lenguaje de tendencias sencillas.